

数据结构：HashMap

题目标签

学习时长：30分钟

题目难度：中等

知识点标签：数据结构、多线程安全、倒插法、位运算/二进制操作、扰动函数、hash碰撞

题目描述

HashMap的内部数据结构？

1.面试题分析

根据题目要求我们可以知道：

- 该题是一个数据结构问题，可以从HashMap的底层数据结构进行分析；
- 建议从多个不同jdk版本进行分析；

分析需要全面并且有深度


容易被忽略的坑

- 分析片面
- 没有深入

2.HashMap数据结构介绍

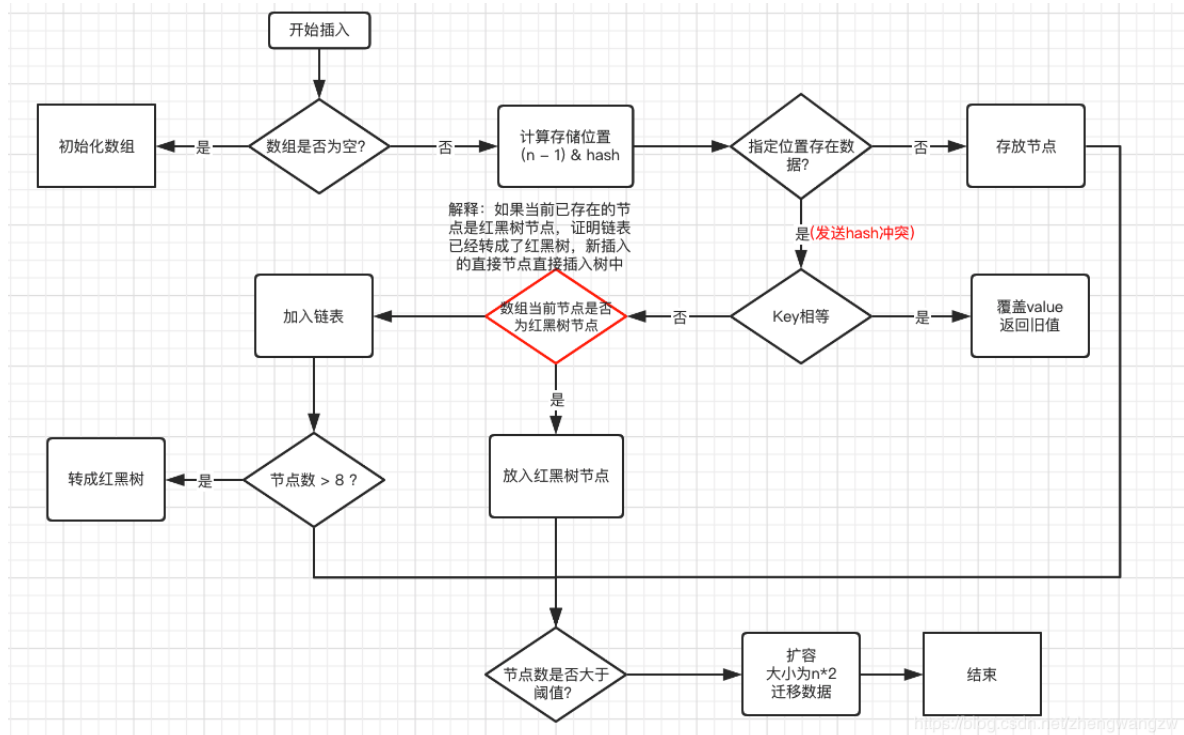
JDK1.8版本的，内部使用数组 + 链表红黑树

数据结构图：



HashMap的数据插入原理

原理图：



1. 判断数组是否为空，为空进行初始化;
2. 不为空，计算 k 的 hash 值，通过 $(n - 1) \& \text{hash}$ 计算应当存放在数组中的下标 index;
3. 查看 `table[index]` 是否存在数据，没有数据就构造一个Node节点存放在 `table[index]` 中;
4. 存在数据，说明发生了hash冲突(存在二个节点key的hash值一样)，继续判断key是否相等，相等，用新的value替换原数据(onlyIfAbsent为false);
5. 如果不相等，判断当前节点类型是不是树型节点，如果是树型节点，创造树型节点插入红黑树中;(如果当前节点是树型节点证明当前已经是红黑树了)
6. 如果不是树型节点，创建普通Node加入链表中;判断链表长度是否大于 8并且数组长度大于64，大于的话链表转换为红黑树;
7. 插入完成之后判断当前节点数是否大于阈值，如果大于开始扩容为原数组的二倍。

HashMap怎么设定初始容量大小?

一般如果 `new HashMap()` 不传值，默认大小是16，负载因子是0.75，如果自己传入初始大小k，初始化大小为 大于k的 2的整数次方，例如如果传10，大小为16。(补充说明:实现代码如下)

```
static final int tableSizeFor(int cap) {  
    int n = cap - 1;  
    n |= n >>> 1;  
    n |= n >>> 2;  
    n |= n >>> 4;  
    n |= n >>> 8;  
    n |= n >>> 16;  
    return (n < 0) ? 1 : (n >= MAXIMUM_CAPACITY) ? MAXIMUM_CAPACITY : n + 1;  
}  
123456789
```

补充说明：下图是详细过程，算法就是让初始二进制右移1，2，4，8，16位，分别与自己位或，把高位第一个为1的数通过不断右移，把高位为1的后面全变为1，最后再进行+1操作， $111111 + 1 = 1000000 = 26$

(符合大于50并且是2的整数次幂)

因为key.hashCode()函数调用的是key键值类型自带的哈希函数，返回int型散列值。int值范围为-2147483648~2147483647，前后加起来大概40亿的映射空间。只要哈希函数映射得比较均匀松散，一般应用是很难出现碰撞的。但问题是一个40亿长度的数组，内存是放不下的。你想，如果HashMap数组的初始大小才16，用之前需要对数组的长度取模运算，得到的余数才能用来访问数组下标。

源码中模运算就是把散列值和数组长度-1做一个"与"操作，位运算比取余%运算要快。

```
bucketIndex = indexFor(hash, table.length);

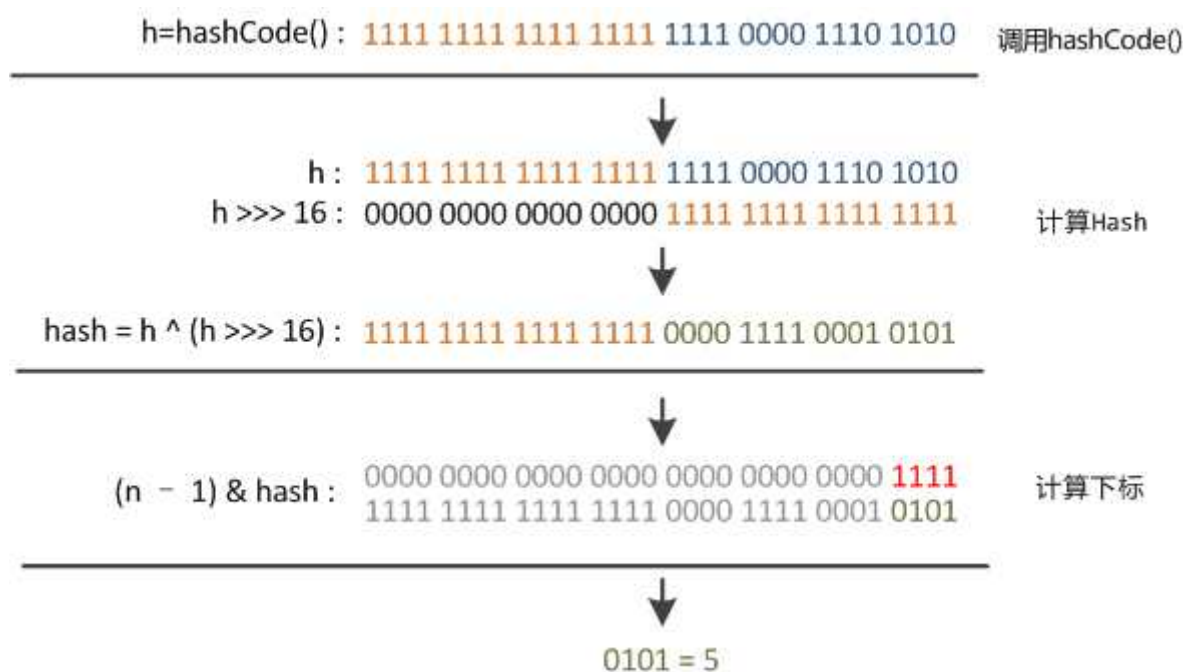
static int indexFor(int h, int length) {
    return h & (length-1);
}
12345
```

这也正好解释了为什么HashMap的数组长度要取2的整数幂。因为这样（数组长度-1）正好相当于一个“低位掩码”。“与”操作的结果就是散列值的高位全部归零，只保留低位值，用来做数组下标访问。以初始长度16为例，16-1=15。2进制表示是00000000 00000000 00001111。和某散列值做“与”操作如下，结果就是截取了最低的四位值。

```
10100101 11000100 00100101
& 00000000 00000000 00001111
-----
00000000 00000000 0000101    //高位全部归零，只保留末四位
1234
```

但这时候问题就来了，这样就算我的散列值分布再松散，要是只取最后几位的话，碰撞也会很严重。更要命的是如果散列本身做得不好，分布上成等差数列的漏洞，如果正好让最后几个低位呈现规律性重复。

此时“扰动函数”的价值就体现出来了，说到这里大家应该猜出来了。看下面这个图，



右移16位，正好是32bit的一半，自己的高半区和低半区做异或，就是为了混合原始哈希码的高位和低位，以此来加大低位的随机性。而且混合后的低位掺杂了高位的部分特征，这样高位的信息也被变相保留下来。

最后我们来看一下Peter Lawley的一篇专栏文章《An introduction to optimising a hashing strategy》里的一个实验：他随机选取了352个字符串，在他们散列值完全没有冲突的前提下，对它们做低位掩码，取数组下标。

Mask	String.hashCode() masked	HashMap.hash(String.hashCode()) masked
32 bits	No collisions	No collisions
16 bits	1 collision	3 collisions
15 bits	2 collisions	4 collisions
14 bits	6 collisions	6 collisions
13 bits	11 collisions	9 collisions
12 bits	17 collisions	15 collisions
11 bits	29 collisions	25 collisions
10 bits	57 collisions	50 collisions
9 bits	103 collisions	92 collisions

结果显示，当HashMap数组长度为512的时候（29），也就是用掩码取低9位的时候，在没有扰动函数的情况下，发生了103次碰撞，接近30%。而在使用了扰动函数之后只有92次碰撞。碰撞减少了将近10%。看来扰动函数确实还是有功效的。

另外Java 1.8相比1.7做了调整，1.7做了四次移位和四次异或，但明显Java 8觉得扰动做一次就够了，做4次的话，多了可能边际效用也不大，所谓为了效率考虑就改成一次了。

下面是1.7的hash代码：

```
static int hash(int h) {
    h ^= (h >>> 20) ^ (h >>> 12);
    return h ^ (h >>> 7) ^ (h >>> 4);
}
1234
```


1.8对hash函数做了优化，1.8还有别的优化？

1. 数组+链表改成了数组+链表或红黑树；
2. 链表的插入方式从头插法改成了尾插法，简单说就是插入时，如果数组位置上已经有元素，1.7将新元素放到数组中，原始节点作为新节点的后继节点，1.8遍历链表，将元素放置到链表的最后；
3. 扩容的时候1.7需要对原数组中的元素进行重新hash定位在新数组的位置，1.8采用更简单的判断逻辑，位置不变或索引+旧容量大小；
4. 在插入时，1.7先判断是否需要扩容，再插入，1.8先进行插入，插入完成再判断是否需要扩容；

优化目的：

1. 防止发生hash冲突，链表长度过长，将时间复杂度由 $O(n)$ 降为 $O(\log n)$ ；
2. 因为1.7头插法扩容时，头插法会使链表发生反转，多线程环境下会产生环；

A线程在插入节点B，B线程也在插入，遇到容量不够开始扩容，重新hash，放置元素，采用头插法，后遍历到的B节点放入了头部，这样形成了环，如下图所示：



1.7的扩容调用transfer代码，如下所示：

```
void transfer(Entry[] newTable, boolean rehash) {
    int newCapacity = newTable.length;
    for (Entry<K,V> e : table) {
        while(null != e) {
            Entry<K,V> next = e.next;
            if (rehash) {
                e.hash = null == e.key ? 0 : hash(e.key);
            }
            int i = indexFor(e.hash, newCapacity);
            e.next = newTable[i]; //A线程如果执行到这一行挂起，B线程开始进行扩容
            newTable[i] = e;
            e = next;
        }
    }
}
```

12345678910111213141516

3. 扩容的时候为什么1.8不用重新hash就可以直接定位原节点在新数据的位置呢？

这是由于扩容是扩大为原数组大小的2倍，用于计算数组位置的掩码仅仅是高位多了一个1，怎么理解呢？

扩容前长度为16，用于计算 $(n-1) \& \text{hash}$ 的二进制 $n-1$ 为0000 1111，扩容为32后的二进制就高位多了1，为0001 1111。

因为是 $\&$ 运算，1和任何数 $\&$ 都是它本身，那就分二种情况，如下图：原数据hashcode高位第4位为0和高位为1的情况；

第四位高位为0，重新hash数值不变，第四位为1，重新hash数值比原来大16（旧数组的容量）

	原始数		二进制		
数组大小为16	0000 0101	&	0000 1111	=	0000 0101
扩容后 数组大小为32	0000 0101	&	0001 1111	=	0000 0101 (和扩容前一致)
	原始数		二进制		
数组大小为16	0001 0101	&	0000 1111	=	0000 0101
扩容后 数组大小为32	0001 0101	&	0001 1111	=	0001 0101 (比扩容前大16)

那HashMap是线程安全的吗？

不是，在多线程环境下，1.7 会产生死循环、数据丢失、数据覆盖的问题，1.8 中会有数据覆盖的问题，以1.8为例，当A线程判断index位置为空后正好挂起，B线程开始往index位置的写入节点数据，这时A线程恢复现场，执行赋值操作，就把A线程的数据给覆盖了；还有++size这个地方也会造成多线程同时扩容等问题。

```
final V putVal(int hash, K key, V value, boolean onlyIfAbsent,
               boolean evict) {
    Node<K,V>[] tab; Node<K,V> p; int n, i;
    if ((tab = table) == null || (n = tab.length) == 0)
        n = (tab = resize()).length;
    if ((p = tab[i = (n - 1) & hash]) == null) //多线程执行到这里
        tab[i] = newNode(hash, key, value, null);
    else {
        Node<K,V> e; K k;
        if (p.hash == hash &&
            ((k = p.key) == key || (key != null && key.equals(k))))
            e = p;
        else if (p instanceof TreeNode) // 这里很重要
            e = ((TreeNode<K,V>)p).putTreeVal(this, tab, hash, key, value);
        else {
            for (int binCount = 0; ; ++binCount) {
                if ((e = p.next) == null) {
                    p.next = newNode(hash, key, value, null);
                    if (binCount >= TREEIFY_THRESHOLD - 1) // -1 for 1st
                        treeifyBin(tab, hash);
                    break;
                }
                if (e.hash == hash &&
                    ((k = e.key) == key || (key != null && key.equals(k))))
                    break;
                p = e;
            }
        }
    }
    if (e != null) { // existing mapping for key
        V oldValue = e.value;
        if (!onlyIfAbsent || oldValue == null)
            e.value = value;
        afterNodeAccess(e);
        return oldValue;
    }
}
```

```
}
++modCount;
if (++size > threshold) // 多个线程走到这，可能重复resize()
    resize();
afterNodeInsertion(evict);
return null;
}
```

123456789101112131415161718192021222324252627282930313233343536373839404142

怎么解决这个线程不安全的问题？

Java中有HashTable、Collections.synchronizedMap、以及ConcurrentHashMap可以实现线程安全的Map。

HashTable是直接在操作方法上加synchronized关键字，锁住整个数组，粒度比较大，Collections.synchronizedMap是使用Collections集合工具的内部类，通过传入Map封装出一个SynchronizedMap对象，内部定义了一个对象锁，方法内通过对象锁实现；ConcurrentHashMap使用分段锁，降低了锁粒度，让并发度大大提高。

3.扩展内容

- ConcurrentHashMap的分段锁的实现原理吗？
- 链表转红黑树是链表长度达到阈值，这个阈值是多少？为什么？
- HashMap内部节点是有序的吗？
- 讲讲LinkedHashMap怎么实现有序的？
- 讲讲TreeMap怎么实现有序的？
- 通过CAS 和 synchronized结合实现锁粒度的降低，讲讲CAS 的实现以及synchronized的实现原理吗？